


Duoc assist ep3



Alumno: FREDDY ALEXANDER RIOS NILO

Profesor: JAIME ANDRES MENENDEZ SILVA

1. Introducción

En esta tercera evaluación se continúa el desarrollo del proyecto DUOC-Assist, iniciado en las evaluaciones anteriores. En esta etapa el objetivo principal fue agregar observabilidad al agente, para poder revisar cómo se comporta durante su ejecución y no solo enfocarse en que entregue una respuesta.

Para esto se implementaron métricas simples como latencia, estado de ejecución, cantidad de consultas con información encontrada, consultas sin información y precisión final del comportamiento del agente. Además, se incorporaron registros de ejecución mediante logs y un archivo CSV donde se almacenan las pruebas realizadas.

También se desarrolló un dashboard básico con gráficos para visualizar los resultados obtenidos. De esta forma, fue posible observar el rendimiento del agente, detectar una falla relacionada con el uso de tildes en las consultas y aplicar una mejora mediante normalización de texto.

Finalmente, se agregó una validación básica de seguridad para rechazar consultas que contengan datos sensibles, como RUT o contraseñas. Esto permite que el agente tenga un comportamiento más responsable y alineado con criterios de privacidad.

2. Implementación de métricas de observabilidad

Para evaluar el comportamiento del agente DUOC-Assist se implementaron métricas de observabilidad simples, pero útiles para analizar su funcionamiento durante las pruebas. Estas métricas fueron registradas automáticamente en un archivo CSV cada vez que el agente recibía una consulta.

Las principales métricas utilizadas fueron la latencia, el estado de ejecución, la cantidad de consultas con información encontrada, la cantidad de consultas sin información y la precisión final del comportamiento del agente. La latencia permitió medir el tiempo que

demoró el agente en entregar una respuesta, mientras que el estado de ejecución permitió identificar si la consulta fue procesada correctamente, rechazada por seguridad o si presentó algún error.

Durante las pruebas finales se realizaron 7 consultas. De ellas, 4 correspondían a preguntas académicas que el agente debía responder, 2 eran preguntas fuera del contexto institucional y 1 contenía un dato sensible, por lo que fue rechazada por seguridad. El agente logró clasificar correctamente estos casos, alcanzando una precisión final del 100% en el conjunto de pruebas utilizado.

La latencia promedio obtenida fue muy baja, debido a que el agente trabaja con una búsqueda local sobre documentos simples y no realiza llamadas externas a un modelo de lenguaje en tiempo real. Esto permitió que las respuestas fueran generadas casi de forma inmediata.

3. Logs y trazabilidad

Para complementar las métricas, se incorporó un sistema de logs que permite registrar las acciones principales del agente durante su ejecución. En estos registros se guardan eventos como consultas realizadas, respuestas generadas, latencia de respuesta, advertencias de seguridad y posibles errores.

El uso de logs permite tener trazabilidad del comportamiento del agente, ya que no solo se observa el resultado final, sino también lo que ocurrió durante el proceso. Esto es importante porque ayuda a revisar si una consulta fue procesada correctamente, si fue rechazada por seguridad o si ocurrió algún error inesperado.

Durante las primeras pruebas se identificó una falla relacionada con la consulta sobre matrícula. El agente no encontraba información porque la palabra “matrícula” venía escrita con tilde en la pregunta, mientras que el tema almacenado estaba escrito como “matricula” sin tilde. Esta diferencia provocó que el sistema no reconociera correctamente la consulta.

A partir de este hallazgo se aplicó una mejora en el procesamiento del texto, incorporando una función de normalización. Con esta mejora, el agente convierte las preguntas a

minúsculas y elimina tildes antes de realizar la búsqueda. Después de aplicar el cambio, la consulta sobre matrícula fue respondida correctamente.

En los registros finales no se detectaron errores de ejecución. Además, se pudo observar que la consulta con RUT fue rechazada por seguridad, quedando registrada como una advertencia dentro del sistema.

4. Dashboard de monitoreo



Para visualizar los resultados obtenidos se desarrolló un dashboard básico dentro del mismo notebook de Google Colab. Este dashboard fue construido mediante gráficos generados con la librería Matplotlib, utilizando como fuente de datos el archivo CSV donde se almacenaron las métricas del agente.

El primer gráfico muestra la cantidad de consultas en las que el agente encontró información y aquellas en las que no encontró contenido relacionado. Este gráfico permite observar que el agente respondió correctamente las preguntas académicas y rechazó las consultas que estaban fuera del contexto institucional.

El segundo gráfico muestra la latencia por consulta. En este caso, los tiempos de respuesta fueron muy bajos, ya que el agente trabaja con documentos locales y reglas simples de búsqueda. Aun así, esta métrica permite comprobar cuánto demora el sistema en entregar una respuesta y sirve como base para futuras comparaciones si el agente se conecta a un modelo de lenguaje o a una base vectorial más grande.

El tercer gráfico representa el estado de ejecución del agente, diferenciando consultas correctas, rechazadas o con error. En las pruebas finales no se presentaron errores de ejecución, y la consulta que contenía un dato sensible fue rechazada correctamente por el sistema.

Estos gráficos permiten observar de forma más clara el comportamiento general del agente y respaldan el análisis realizado a partir de las métricas.



5. Seguridad y uso responsable

Como parte del desarrollo del agente, se agregó una validación básica para evitar el procesamiento de consultas que puedan contener datos sensibles. Esta medida busca que el agente no almacene ni procese información personal que no sea necesaria para responder una consulta académica.

Para esto se creó una función que revisa la pregunta ingresada por el usuario antes de enviarla al proceso de búsqueda. Si la consulta contiene palabras relacionadas con datos sensibles, como RUT, contraseña, clave, dirección o teléfono, el sistema rechaza la solicitud y entrega un mensaje indicando que no será procesada.

Durante las pruebas se ingresó una consulta que contenía un RUT. El agente identificó esta información como sensible y rechazó correctamente la consulta. Además, este evento quedó registrado en los logs como una advertencia de seguridad.

Esta validación es simple, pero permite demostrar una primera medida de uso responsable. En una versión futura del sistema, esta parte podría mejorarse incorporando filtros más avanzados para detectar datos personales y aplicar políticas de privacidad más completas.

6. Recomendaciones y conclusión

A partir de las pruebas realizadas, se puede concluir que el agente DUOC-Assist logró un funcionamiento correcto dentro del conjunto de consultas evaluadas. El sistema respondió las preguntas académicas disponibles, rechazó consultas fuera del contexto institucional y bloqueó una consulta con información sensible.

Una mejora importante fue la normalización del texto, ya que permitió corregir el problema detectado con la palabra “matrícula”. Esto demuestra que revisar los logs y las métricas ayuda a encontrar fallas pequeñas que pueden afectar el comportamiento del agente.

Como recomendación futura, se propone ampliar la cantidad de documentos utilizados por el agente, incorporar una base vectorial más completa y mejorar la detección de datos personales. También sería útil conectar el sistema a un modelo de lenguaje o a un motor RAG más avanzado, para responder preguntas con mayor variedad sin perder el control de seguridad.

En conclusión, la implementación de observabilidad permitió analizar el desempeño del agente de forma más clara, usando métricas, logs y gráficos. Esto ayuda a mejorar la confiabilidad del sistema y permite tomar decisiones basadas en evidencia.

7. Referencias

Duoc UC. (2025). Evaluación Parcial N°3: Implementación de Observabilidad.

LangChain. (2025). LangChain documentation.

Matplotlib. (2025). Matplotlib documentation.

Python Software Foundation. (2025). Python documentation.